

OVERVIEW OUR TEAM TIMELINE RESULT REVIEW

배경 팀 구성 수행 절차 수행 결과



KOIUS



Except where otherwise noted, this work is licensed under http://creativecommons.org/licenses/by/3.0/

VOD 서비스 이용 정보 분석 시스템

REQUEST


- ① 새로운 인사이트
- ② 고객친화
- ③ **상용화**
- ④ 최소비용 최대효율

RESTRICTION

- ① 실시간
- ② 처리량 (일 30GB↑)
- ③ 자동화
- ④ 오픈소스
- ⑤ 연관성 분석 지양

WHY?

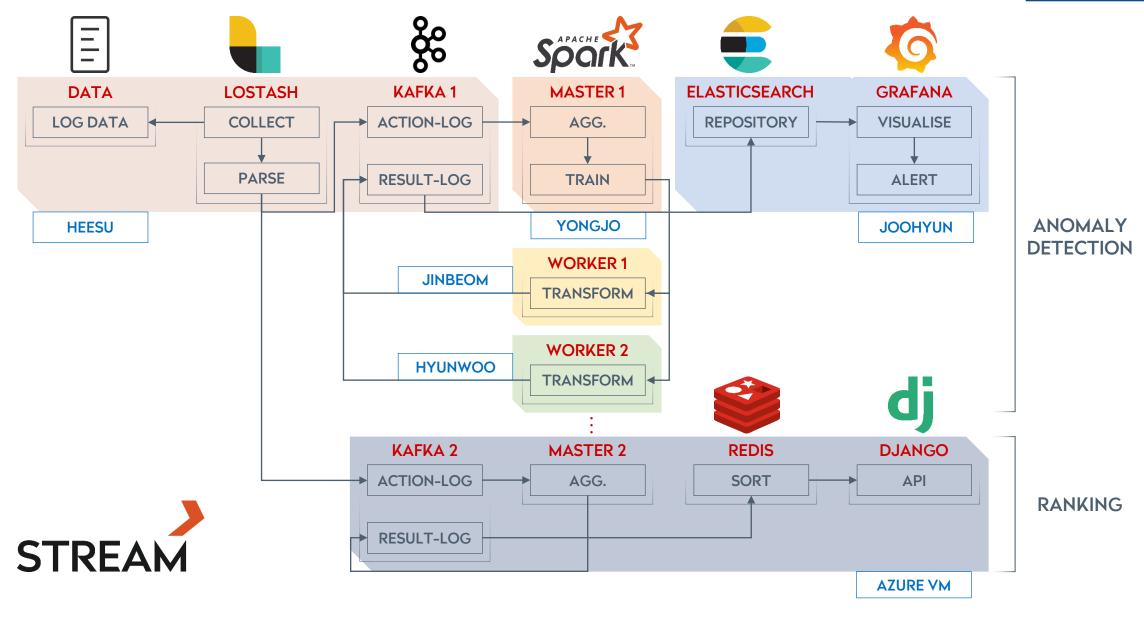
- ① 메타데이터 부재
- ② 고객 핵심자산 접근 불가
- ③ 기존 방식의 한계
- ④ 'JSON', '빅' 데이터



megastudyedu

Possession Top 10









다오. "당신들이 원하는 바를 다오(DAO). 우리가 줄게."

MEET OUR TEAM.











김주현

РМ

신희수

PL

김용조


ENGINEER

김진범

ANALYST

이현우

RESEARCHER





계획 수립

분석

설계

- ① 스트리밍 데이터 시각화
- ② 산업체 요구사항 구체화
- ③ R&R, WBS, 개발계획 수립
- ④ 미니프로젝트 최종평가 준비

- ① Action Log 필드 분석
- ② 개발환경 조사 및 분석
- ③ 이상감지 알고리즘 스터디
- ④ 랭킹 파이프라인 스터디

① 개발환경 설계

3

- ② 스트리밍 파이프라인 설계
- ③ 이상감지, 랭킹 설계

① 개발환경 픽스 및 구축

② 이상감지, 랭킹 PoC

① 이상감지, 랭킹
Pilot 테스트

② 중간 평가 준비

① 이상감지, 랭킹 고도화 및 시각화

② 최종 평가 준비

③ 데모데이 준비

 4
 5
 6
 고도화







CPMS=^N20171204015852983469C0C765FEDFE3E23F_4266^; Tride 3", "year": "2020", "hit":1, "pfkey": "ttschool-pc1-

우리가 알고 싶은 것

어떤 무언가가 "hit"에 영향을 미치는가? 0 고객들의 "hit"의 상태가 **지금** 이상한가? 0 고객의 어떤 콘텐츠의 "hit" 가 **지금** 핫한가?

Kollus로 VOD 재생 시 발생하는 비정형 데이터

우리에게 필요한 데이터

구분 가능한 키, 셀 수 있는 **밸류**가 있는 **시계열** 데이터


LOGSTASH

INPUT: FILE

OUTPUT: KAFKA


```
filter {
     json {
         source => "message"
    mutate {
         add_field => { "cpk" => "%{[_source][@fields][params][cpk]}" }
         add_field => { "time" => "%{[_source][logdate]}" }
         add_field => { "hit" => "%{[_source][@fields][params][hit]}" }
         add_field => { "base_mck" => "%{[_source][@fields][params][base_mck]}" }
         convert => {
             "hit" => "integer"
     prune {
         whitelist_names => ["cpk", "hit", "base_mck", "time"]
```

PIPELINE






KMEANS++





Before we implemented Spark

```
from keras.layers.recurrent import SimpleRNN
from keras.layers.recurrent import LSTM
from keras.layers.recurrent import GRU
from alibi_detect.od import OutlierProphet
from alibi_detect.od import OutlierSeq2Seq
from pyod.models import OCSVM
from pyod.models import LOF
from pyod.models import CBLOF
from pyod.models import HBOS
from pyod.models import KNN
from pyod.models import AvgKNN
from pyod.models import IForest
from pyod.models import XGBOD
from rrcf import RCTree
```



PIPELINE





KAFKA to SPARK

AGGREGATION

SPARK to KAFKA

```
df = spark.readStream.format("kafka") \
    .option("kafka.bootstrap.servers", "<ip-address>:9092") \
    .option("subscribe", "action-log") \
    .option("startingOffsets", "latest") \
    .load()
streamingDF = action detail df \
    .withWatermark("timestamp", "10 seconds") \
    .groupBy(
        window("timestamp", "10 seconds"),
        action_detail_df.cpk, action_detail_df.base_mck) \
    .agg(count("*")) \
    .select("cpk", "base mck", col("count(1)"), "window")
kafka_stream_dataframe = streamingDF \
    .selectExpr("CAST(cpk AS STRING) AS key", "to_json(struct(*)) AS value") \
    .writeStream.trigger(processingTime='10 seconds') \
    .format("kafka") \
    .option("kafka.bootstrap.servers", "<ip-address>:9092") \
    .option("topic", "result-log") \
    .outputMode("update") \
    .option("checkpointLocation", "./tmp/checkpoint") \
    .start()
```

kafka_stream_dataframe.awaitTermination()



RESOURCE



LATENCY



METRIC



KMEANS




GET THROUGH


- ▶ 한정된 자원, 닫힌 네트워크
- ▶ 처리 지연 없이 실시간으로
- ▶ 어떤 상황에서도 실시간으로

만족도



- 수치형 지표 고안 ◀
- 이상감지 활용 범위 확대 ◀
- 지속가능성, 안정성 확보 ◀









Except where otherwise noted, content on this slide is licensed under a Creative Commons Attribution 4.0 International license. Generated by Joohyun Keem.



본 문서는 16:9 FHD(1920x1080) 환경에 최적화되어 있습니다.